

Lỗi 3 — CV và so khớp JD


Lỗi 3 biến CV và tin tuyển dụng (JD) thành hai tập `skill_id` trên cùng một từ điển kỹ năng, rồi tính tỉ lệ khớp giữa chúng. CV, JD, học phần và câu hỏi phỏng vấn đều trở tới bằng `skills`, nên gap từ JD khớp thẳng với học phần mà không cần bước dịch. Lỗi thuộc con đường sự nghiệp của Candidate (bước 5 và 6 trong chu trình DevRoom) và là nguồn dữ liệu cho Recruiter tìm ứng viên. Đầu ra là % match, danh sách kỹ năng thiếu (gap) và đề xuất học phần đẩy ngược về lỗi học thích ứng. Ba engine của tài liệu kỹ thuật gộp trong lỗi này: E6 (bóc tách và chấm CV), E7 (thu thập và chuẩn hoá JD), E8 (matching).

1. Nghiệp vụ

Hai luồng vào, một trục chung, hai chiều ra.

#	Bước	Ai	Kết quả
1	Upload CV PDF/DOCX hoặc dùng CV do AI tạo	Candidate	<code>cvs</code> (raw_text, cv_json, embedding), <code>cv_skills</code> theo <code>skill_id</code>
2	Chấm CV theo JD mục tiêu	Hệ thống	<code>score_rule</code> 0–100, gợi ý sửa, cờ ATS
3	Thu JD từ ① crawler theo lịch, ② agent tìm web theo yêu cầu, ③ Recruiter nhập	Hệ thống, Recruiter	<code>jd_postings</code> chuẩn hoá, <code>jd_skills</code> theo <code>skill_id</code> , bản trùng gắn <code>duplicate_of</code>
4	Xem feed việc làm, chọn một JD	Candidate	% match, <code>skill_match</code> , cosine, gap từng skill
5	Tạo đề xuất cải thiện từ gap	Candidate	<code>suggestions(status='pending')</code> chờ nhận hoặc bỏ qua ở roadmap
6	Tìm ứng viên cho một JD	Recruiter	Danh sách ẩn danh xếp theo <code>recruiter_score</code> , lọc <code>min_match</code>
7	Admin duyệt hàng đợi <code>unmapped_skills</code> , chỉnh trọng số	Admin	Alias mới, <code>settings.match_weights</code>

2. Sơ đồ



Đọc từ trên xuống. Hàng đầu là hai luồng vào: CV đi qua upload → bóc chữ → trích xuất LLM; JD đi từ ba nguồn vào một pipeline chuẩn hoá chung. Cả hai đổ chuỗi kỹ năng thô vào dải màu navy `map_skill(raw)` ba tầng và chỉ đi tiếp khi đã có `skill_id`. Hàng ba là phần riêng của mỗi luồng sau chuẩn hoá: CV được embedding và chấm điểm, JD được khử trùng lặp và embedding phần yêu cầu. Khối so khớp ở giữa nhận `cv_skills`, `emb_cv`, `jd_skills`, `emb_jd` và thêm `skill_states` từ lỗi học (mũi tên teal). Từ đó toả ra chiều thuận cho Candidate (% match, gap, đề xuất pending) và chiều ngược cho Recruiter (xếp hạng N ứng viên). Mũi tên teal dưới cùng là vòng phản hồi về roadmap.

3. Nguyên lý hoạt động

3.1 Pipeline trích xuất CV (E6)

```
upload (≤ 5 MB, .pdf/.docx, magic bytes) → object storage private
→ PyMuPDF page.get_text("blocks") | python-docx paragraphs
→ len(text) < 200 → parse_status='scanned_unsupported' (không OCR ở MVP)
→ cluster block theo cột, sort theo y (CV 2 cột)
→ Claude Sonnet 5, temperature 0, JSON schema
  {full_name, headline, email, phone, links, years_total,
   skills[{raw, years, level, evidence_span}], experiences[bullets{text, has_metric}],
   projects, education, page_count, ats_flags}
→ map raw → skill_id (3 tầng, §3.2) → cv_skills
→ bge-m3(toàn văn rút gọn) → cvs.embedding vector(1024)
```

Số năm kinh nghiệm và vai trò do LLM trả về theo schema; demo thay bằng regex `(\d+)\s*\+?\s*(năm|years?)` lấy giá trị lớn nhất và bằng `title_map` trên dòng headline.

3.2 Chuẩn hoá về skill_id ba tầng (dùng chung CV và JD)

Tầ ng	Điều kiện	Kết quả
1	<code>lower(trim(raw)) = lower(skills.name_en</code>	<code>name_vì)</code>
2	<code>lower(trim(raw)) = lower(skill_aliases.alias) (UNIQUE lower(alias))</code>	<code>skill_id, map_method='alias'</code>
3	<code>cosine(embed(raw), skills.embedding) ≥ 0,85</code> trên top-3 HNSW, và cặp (top-1, top-2) không thuộc <code>skill_confusion_blocklist</code>	<code>skill_id, map_method='cosine', map_cos</code>
–	Không đạt	<code>unmapped_skills(raw_text, freq += 1, best_guess, best_cos) → Admin thêm alias</code>

```
def map_skill(raw):
    k = norm(raw)
    if hit := exact_lookup(k): return hit, "exact", 1.0
    if hit := alias_lookup(k): return hit, "alias", 1.0
    rows = knn_skills(embed(raw), k=3) # 1 - (a <= b) trong pgvector
    if rows and rows[0].cos >= CFG.cos_threshold:
        if (rows[0].skill_id, rows[1].skill_id) not in BLOCKLIST:
            return rows[0].skill_id, "cosine", rows[0].cos
    enqueue_unmapped(raw) # giữ raw, không tạo skill mới
    return None, "unmapped", rows[0].cos if rows else 0.0
```

Bất biến: mọi dòng `cv_skills` và `jd_skills` có `skill_id` NOT NULL hoặc `raw_text` tồn tại trong `unmapped_skills`. Chuỗi gốc không bao giờ bị bỏ.

3.3 Chấm CV theo quy tắc

#	Quy tắc	Điểm
R0	Điểm nền	+40

#	Quy tắc	Điểm
R1	Có <code>full_name</code> và <code>headline</code>	+10
R2	Mỗi bullet kinh nghiệm có số liệu	+6/bullet, cap +18
R3	Bullet dài > 140 ký tự	-5/bullet
R4	≥ 3 bullet kinh nghiệm/dự án	+8
R5	Link GitHub hợp lệ	+8
R6	Liệt kê ≥ 4 skill cụ thể	+6
R7	Mỗi skill của JD mục tiêu không có trong <code>cv_skills</code>	-4/skill
R8	<code>page_count</code> ∈ {1, 2}	+5, ngoài dải -5
R9	Không có <code>ats_flags</code>	+4
R10	Có email và phone	+3

`score_rule = clamp(round(ΣR), 0, 100)` . Bản thật cộng thêm rubric LLM 4 mục (rõ ràng, tác động, phù hợp JD, gọn) mỗi mục 0-5: `score_llm = Σ/20·100` , `score_final = 0,5·score_rule + 0,5·score_llm` , chấm 2 lần lấy trung bình. Gợi ý sửa từ LLM chỉ được giữ khi `evidence_span` là chuỗi con nguyên văn của `cv_text` ; skill mới phải có `needs_user_confirm = true` .

3.4 Thu JD từ ba nguồn và chuẩn hoá (E7)

Nguồn	source	trust_weight	Cách thu
① Crawler	<code>crawler</code>	0,8	Crawlee + Playwright, TopCV và ITviec, Celery beat 07:00 và 19:00, ≤ 200 tin/lần, lưu HTML thô trước khi parse
② Agent tìm web	<code>web_search</code>	0,6	Tavily/Brave khi Candidate bấm tìm thêm; Haiku 4.5 lọc <code>is_job_posting</code> , bỏ nếu <code>confidence < 0,7</code> ; 10 query/ngày
③ Recruiter	<code>recruiter</code>	1,0	Form; LLM bóc skill rồi Recruiter sửa <code>required</code> , <code>weight_1_3</code> và xác nhận

Pipeline chung: parse (trafilatura/PyMuPDF/form) → Haiku 4.5 JSON {`title`, `company`, `level`, `city`, `salary`, `skills`[{`name`, `required`, `weight`, `years`}]} → map skill 3 tầng → bge-m3 trên `title` + `skills` + `responsibilities` → dedupe → `status='published'` → `recompute_match(jd_id)` . Chỉ embed phần yêu cầu, không embed phúc lợi để cosine không bị boilerplate kéo lên.

3.5 Khử trùng lặp

- `content_hash = sha256(lower(trim(title)) || '|' || lower(trim(company)) || '|' || normalized_desc)` ; `normalized_desc` bỏ HTML, hạ chữ, gộp khoảng trắng, bỏ số điện thoại, email, số. Trùng hash → cùng tin.
- Gần đúng: cùng `company` hoặc cùng `career` , cách nhau ≤ 30 ngày, `cosine(embedding) ≥ 0,95` và `similarity(title) ≥ 0,8` (pg_trgm).
- Chọn bản giữ theo thứ tự: nguồn ③ > ① > ②; mô tả dài hơn; `posted_at` mới hơn; `id` nhỏ hơn.
- Bản bị loại: `status='duplicate'` , `duplicate_of = id` giữ lại, ghi `jd_duplicates(kept_id, dropped_id, reason, cos)` . Không xoá.

3.6 Công thức so khớp (E8)

<code>match</code>	= <code>w_skill · skill_match + w_cos · cosine(emb_cv, emb_jd_requirements)</code>	(0,7 / 0,3)
<code>skill_match</code>	= $\sum_i w_i \cdot c_i / \sum_i w_i$	<code>i</code> chạy qua mọi skill của JD
<code>w_i</code>	= <code>weight_1_3(i) · (1,0 nếu required, 0,5 nếu nice_to_have)</code>	
<code>Have</code>	= { <code>skill_id</code> ∈ <code>cv_skills</code> } ∪ { <code>skill_id</code> ∈ <code>skill_states</code> : <code>proficiency ≥ 60</code> }	

c	Điều kiện	Ý nghĩa
1	<code>skill_id(i) ∈ Have</code>	Có sẵn, từ CV tự khai hoặc từ lỗi học đo được

c	Điều kiện	Ý nghĩa
0,5	Tồn tại $j \in \text{Have}$ với $\text{broader_id}(i) = \text{broader_id}(j)$ hoặc $\text{cosine}(\text{emb}_i, \text{emb}_j) \geq 0,8$	Họ hàng gần, học nhanh nhưng không bằng có sẵn
0	Còn lại	Thiếu hẳn, đưa vào gap

```
-- pgvector: <=> là cosine distance, cosine_sim = 1 - (a <=> b); index HNSW vector_cosine_ops
WITH cfg AS (SELECT (v->>'w_skill')::float ws, (v->>'w_cos')::float wc FROM settings WHERE k='match_weights'),
have AS (SELECT skill_id FROM cv_skills WHERE cv_id = $1
         UNION SELECT skill_id FROM skill_states WHERE room_id = $2 AND p >= 60),
sm AS (SELECT js.jd_id,
          SUM(js.weight_1_3 * (CASE WHEN js.required THEN 1.0 ELSE 0.5 END) *
            CASE WHEN js.skill_id IN (SELECT skill_id FROM have) THEN 1.0
              WHEN EXISTS (SELECT 1 FROM have h JOIN skills a ON a.skill_id = js.skill_id
                           JOIN skills b ON b.skill_id = h.skill_id
                           WHERE a.broader_id = b.broader_id
                              OR 1 - (a.embedding <=> b.embedding) >= 0.8) THEN 0.5
              ELSE 0.0 END)
        / NULLIF(SUM(js.weight_1_3 * (CASE WHEN js.required THEN 1.0 ELSE 0.5 END)), 0) AS skill_match
        FROM jd_skills js GROUP BY js.jd_id)
SELECT j.id, ROUND((cfg.ws * sm.skill_match + cfg.wc * (1 - (c.embedding <=> j.embedding))):numeric, 4) AS
match
FROM jd_postings j JOIN sm ON sm.jd_id = j.id JOIN cvs c ON c.id = $1 CROSS JOIN cfg
WHERE j.status = 'active' ORDER BY match DESC LIMIT 50;
```

Công thức tuyến tính được chọn thay LightGBM vì chưa có nhãn "được mời/được tuyển", vì giải thích được từng skill mất bao nhiêu điểm, và vì đối trọng số chỉ là một dòng settings.

3.7 Chiều ngược: 1 JD × N ứng viên

```
recruiter_score = match_score + 0,1 · (mock_score / 10)    mock cùng career
tie-break: last_active_at mới hơn
```

Precompute vào bảng `matches` khi JD tạo/sửa (`UPSERT ON CONFLICT (jd_id, candidate_id)`) và refresh 02:00 hằng ngày. Recruiter nhận danh sách ẩn danh, lọc `min_match`; mở hồ sơ mới ghi `audit_logs` và tính phí.

3.8 Sinh đề xuất từ gap

```
def suggest_from_gap(candidate, room, jd, match):
    n = 0
    for s in match.gap:
        m = first_module_with_skill(s)
        if m is None or m.id in roadmap_items(room):
            continue
        if pending_exists(room, m.id):
            continue # UNIQUE partial index
        insert_suggestion(room, m.id, origin="jd_match",
            reason=f"Match {jd.id} {jd.title} ({match.pct}%): thiếu {s.name}",
            priority=match.w[s], status="pending")
        n += 1
    return n
```

Candidate nhận → `roadmap_items(source='from_suggestion', position=0)`; bỏ qua → không đổi.

3.9 Phần mô phỏng trong demo

Tầng 3 dùng độ giống chuỗi Jaro–Winkler giữa `raw` và tên/alias, ngưỡng 0,85, thay cho cosine embedding bge-m3. Cosine giữa CV và JD dùng vector bag-of-skills ($v[s] = p/100$, tối thiểu 0,6 nếu có trong CV; $y[s] = 1$ cho skill của JD)

thay cho embedding văn bản. Cosine dedupe dùng bag-of-words trên `normalized_desc` ; hash dùng cyrb53 64 bit thay sha256. Tiêu chí $\text{cosine}(\text{emb}_i, \text{emb}_j) \geq 0,8$ của $c_i = 0,5$ không mô phỏng, chỉ dùng cùng nhánh cha.

4. Dữ liệu

Đầu vào so khớp (rút gọn):

```
{
  "cv_id": "cv_u1",
  "room_id": "r1",
  "cv_skills": ["S_react", "S_ts", "S_css", "S_cicd", "S_statemgmt", "S_testing"],
  "skill_states": {
    "S_js": 82,
    "S_react": 76,
    "S_css": 70,
    "S_http": 41,
    "S_testing": 52,
    "S_git": 68
  },
  "jd": {
    "id": "j1",
    "skills": [
      {
        "skill_id": "S_react",
        "required": true,
        "weight_1_3": 3
      },
      {
        "skill_id": "S_http",
        "required": true,
        "weight_1_3": 2
      },
      {
        "skill_id": "S_ts",
        "required": false,
        "weight_1_3": 1
      }
    ]
  }
}
```

Đầu ra:

```
{
  "jd_id": "j1",
  "skill_match": 0.810,
  "cos_sim": 0.830,
  "match_score": 0.816,
  "match_pct": 82,
  "rows": [
    {
      "skill_id": "S_http",
      "w": 2,
      "c": 0,
      "why": "không có → gap"
    }
  ],
  "gap": ["S_http"],
  "suggestions_created": 1
}
```

Bảng	Cột chính
skills	skill_id, name_en, name_vi, broader_id, branch, embedding
skill_aliases	id, skill_id, alias (UNIQUE lower(alias)), lang, added_by
unmapped_skills	id, raw_text, freq, best_guess_skill_id, best_cos, status, resolved_by
cvs	id, candidate_id, source, file_url, raw_text, cv_json, page_count, parse_status, embedding
cv_skills	cv_id, skill_id, raw_text, years, level, map_method, map_cos, confirmed_by_user
cv_scores	id, cv_id, jd_id, score_rule, score_llm, score_final, rubric_json, tips_json, run_no
jd_postings	id, source, trust_weight, url_canonical, content_hash, company_id, title_normalized, seniority, province_code, salary_min/max, requirements_text, embedding, status, duplicate_of, posted_at
jd_skills	jd_id, skill_id, raw_text, required, weight_1_3, years_min, map_method, map_cos
jd_duplicates	kept_id, dropped_id, reason, cos
matches	jd_id, candidate_id, skill_match, cos_sim, match_score, gap, computed_at
suggestions	id, room_id, module_id, skill_id, origin, reason, priority, status
settings, settings_history	k='match_weights', v={'w_skill':0.7, 'w_cos':0.3}, CHECK w_skill + w_cos = 1

5. Tham số cấu hình

Tên	Mặc định	Ảnh hưởng
skill_map_cos_threshold	0,85	Hạ → nhiều false positive ở tầng 3; nâng → unmapped phình
cv_bullet_max_len	140	R3
cv_metric_bonus_cap	18	R2
cv_missing_skill_penalty	−4	R7, ảnh hưởng lớn khi JD nhiều skill
cv_rule_llm_weight	0,5 / 0,5	Ổn định (rule) vs tinh tế (LLM)
jd_neardup_cos	0,95 (§4.3; §2.7 ghi 0,93)	Gộp sai JD khác nhau nếu hạ
jd_neardup_window_days	30	Tin đăng lại theo mùa

Tên	Mặc định	Ảnh hưởng
trust_weight	1,0 / 0,8 / 0,6	Bản nào được giữ khi trùng
w_skill / w_cos	0,7 / 0,3	Nghiêng về skill rời hay ngữ nghĩa toàn văn
c_half_cosine	0,8	Khi nào tính khớp một nửa
p_pass_for_have	60	Skill đo được nào tính là "có"
nice_to_have_factor	0,5	Trọng số skill không bắt buộc
recruiter_mock_bonus	0,1	Mock ảnh hưởng thứ hạng

6. Kiểm chứng

#	Đầu vào	Đầu ra mong đợi
T 1	CV A, dòng kỹ năng "ReactJS, Typescript, Java Script, CSS3, Github Action, Redux Toolkit, Figma"	11 cụm từ (kể cả quét nội dung): exact 2, alias 6, cosine 1 ("Github Action" ≈ "GitHub Actions" 0,986 → S_cicd), unmapped 2 ("Java Script": top-1 JavaScript 0,982, top-2 Java 0,873, cặp blacklist; "Figma": 0,606 < 0,85). 6 skill_id, years_total = 2
T 2	Admin thêm alias "Java Script" → JavaScript	Trích xuất lại: "Java Script" khớp tầng 2, hàng đợi unmapped giảm 1, CV A có thêm S_js
T 3	CV A với JD j1	R7 trừ 12 (thiếu JavaScript, HTTP/REST, Git), R3 trừ 5 (1 bullet 214 ký tự) → score_rule = 73
T 5	j1 và j2 (cùng công ty, khác 1 từ)	cos 0,968 ≥ 0,95, title 0,833 ≥ 0,8 → j2 duplicate_of = j1 (j1 dài hơn 3 ký tự)
T 6	j5 (Recruiter) và j6 (agent, cùng văn bản)	content_hash bằng nhau → giữ j5 vì nguồn ③ > ②
T 7	Dán JD crawler gần giống j12 (Recruiter)	cos 0,966, title 0,882 → bản dán duplicate_of = j12, lý do nguồn ③ > ①
T 8	CV A × j1	skill_match = 8,5/10,5 = 0,810, cos = 0,830, match = 0,7·0,810 + 0,3·0,830 = 0,816 → 82 %, gap = HTTP/REST
T 9	CV A × j4	HTML c1 = 0,5 (cùng nhánh Giao diện với CSS), Vue c1 = 0,5 (cùng nhánh Framework với React); skill_match = 8/9
T 10	Đổi w_skill 0,7 → 0,5 → 0,3	CV A × j4: 81 → 75 → 70; CV B × j11: 74 → 71 → 67. JD có cos cao, skill thấp leo hạng
T 11	Thêm 1 skill vào Have (u3 thêm S_http)	match 0,611 → 0,745, không bao giờ giảm (đơn điệu)
T 12	Candidate 0 skill, CV rỗng	skill_match = 0, cos = 0 → match = 0 ≤ 0,3
T 13	Bấm "Tạo đề xuất" hai lần cho CV A × j1	Lần 1 tạo 1 đề xuất (học phần HTTP, REST API và caching); lần 2 tạo 0, lý do "đang pending"
T 14	SQL và hàm Python trên cùng dữ liệu	Lệch ≤ 1e-6 (golden test hai đường code)
T 15	Golden set map skill 300 chuỗi, quét ngưỡng 0,75 → 0,95	Chọn ngưỡng có precision ≥ 0,95; top-1 accuracy ≥ 0,90; unmapped_rate < 10 %

7. Demo

Chạy [demo.html](#). Một file, không backend, trạng thái lưu trong localStorage, nút Reset seed lại.

Thao tác	Quan sát được
Mục 1: kéo ngưỡng tầng 3 xuống 0,70	"Terraform" và "Prometheus" bị map sai (false positive); kéo lên 0,99 thì "Github Action", "Dockerr" rơi vào unmapped
Mục 1: gán alias cho cụm trong hàng đợi	Ba CV được trích xuất lại, hàng đợi giảm, nhật ký ghi alias mới
Mục 2: chọn CV A/B/C, sửa văn bản, bấm Trích xuất	Bảng cụm từ → tầng khớp → skill_id ; top-3 và điểm JW cho cụm unmapped; years bắt bằng regex kèm ngữ cảnh
Mục 3: đổi JD mục tiêu	R7 đổi theo skill thiếu, tổng điểm và gợi ý đổi ngay
Mục 4: bấm "Chạy pipeline chuẩn hóa" rồi "Chạy khử trùng lặp"	Hash rút gọn, 8 cặp cosine cao nhất, cặp bị coi là trùng, bản được giữ và lý do
Mục 5: chọn CV và JD, kéo trọng số	Bảng w _i , c _i , lý do từng skill; hai vector số; cosine tính ra; % đổi theo trọng số
Mục 6: đổi JD	10 ứng viên xếp lại theo recruiter_score , cột mock và Verified
Mục 7: bấm "Tạo đề xuất từ gap"	Đề xuất pending theo học phần, lần bấm sau không tạo trùng
Mục 8	Nhật ký từng bước với số

Phần	Thật hay mô phỏng
Tầng 1, 2 (tên, alias), blocklist, hàng đợi unmapped	Logic thật
Tầng 3	Mô phỏng bằng Jaro–Winkler; bản thật dùng cosine bge-m3 qua pgvector
Trích xuất cụm từ, years, headline	Mô phỏng bằng regex và quét n-gram; bản thật dùng Sonnet 5 JSON schema
Bộ quy tắc R0–R10	Logic thật, page_count ước từ độ dài, ats_flags chỉ kiểm ký tự tab
score_llm , gợi ý sửa từ LLM	Không có trong demo
content_hash , quy tắc giữ bản, cửa sổ 30 ngày, title trigram	Logic thật; hash cyrb53 thay sha256; cosine bag-of-words thay embedding
Công thức match, w _i , c _i , Have, trọng số Admin	Logic thật; cosine dùng vector bag-of-skills
Chiều ngược, recruiter_score , sinh đề xuất, chặn trùng pending	Logic thật trên 10 ứng viên và roadmap seed cố định

8. Hạn chế

Hạn chế	Hệ quả
Điểm rule là heuristic tự đặt, đo hình thức CV	Không đo năng lực thật; R7 khuyến khích nhồi keyword, cần giới hạn cv_missing_skill_penalty
CV nhiều cột, chữ trong ảnh	Bóc chữ sai thứ tự; MVP không OCR
Cosine tầng 3 nhằm cặp gần nghĩa (React / React Native, Java / JavaScript)	Bắt buộc blocklist dựng từ golden set; cụm hợp lệ như "Java Script" vẫn phải qua Admin
c ₁ = 1 không phân biệt biết sơ và 3 năm kinh nghiệm	years_min của JD chưa vào công thức
Trọng số 0,7/0,3 chọn tay, chưa có nhãn	Chỉ chứng minh được nhất quán và giải thích được; nhãn đầu tiên là tỉ lệ candidate match ≥ 0,7 được mời
Weight của skill JD nguồn ①② do LLM gán	Trọng số sai thì skill_match sai; nguồn ③ có Recruiter xác nhận nên đáng tin hơn